基于纯NumPy的双层 ReLU 网络对复杂非线性函数的拟合研究

一．函数定义与特性分析 (Function Definition)

为了全面验证神经网络的万能逼近能力，本实验刻意避开了简单的线性或单调函数，而是构造了一个结合了局部剧烈震荡与全局发散趋势的复合函数。目标函数定义为：

$$f(x) = \sin(\pi x) + 0.5x^2$$

设计动机与函数特性：

1）高频周期性波动：公式中的 $\sin(\pi x)$ 部分引入了周期性的非线性震荡。这要求神经网络必须具备足够的灵活性（即隐藏层具有足够的神经元），才能在不同的局部区间内精准“弯折”以贴合正弦曲线。

2）全局二次增长趋势：公式中的 $0.5x^2$ 赋予了函数一个开口向上的抛物线基底。随着 x 绝对值的增大，函数值迅速上升。

3）拟合难点：传统的浅层机器学习模型（如低阶多项式回归）很难同时兼顾局部的周期震荡和全局的二次趋势。若多项式阶数过高又极易产生龙格现象（Runge’s phenomenon）。因此，该函数是检验神经网络非线性映射能力的绝佳基准（Benchmark）。

二、 数据采集与预处理策略 (Data Collection)

深度学习本质上是由数据驱动的。为了模拟真实的观测环境并客观评估模型的泛化能力，本实验对训练集和测试集进行了严格的隔离与差异化处理。

- 数据域选择：设定自变量的采样区间为 [-3, 3]。在该区间内，函数经历了多个正弦周期，且二次函数的发散趋势已经十分明显。
- 训练集构造 (Training Set)：

1）采样方法：在区间内使用均匀分布随机采样 2000 个独立数据点。庞大的数据量为网络提供了充足的更新依据。

2）噪声注入：为了防止神经网络发生“死记硬背”式的过拟合（Overfitting），我们为每个样本的真实函数值人为添加了服从高斯分布的白噪声 $\mathcal{N}(0,0.1^2)$。这模

拟了真实物理世界中传感器采集数据时不可避免的测量误差，迫使模型去学习潜藏的“规律”而非表面的“噪点”。

- 测试集构造 (Test Set)：

o 在相同区间内等距采样 500 个点，不添加任何噪声。测试集的唯一作用是作为“上帝视角”的 Ground Truth，用于在训练结束后，严谨地评估模型是否真正还原了底层的物理规律。

三、 模型架构与核心数学原理解析 (Model Description)

本实验最核心的亮点在于：完全摒弃了现代自动微分框架，仅使用基础矩阵乘法从零构建了包含反向传播和高级优化器的神经网络。

1. 网络拓扑结构 模型采用标准的单隐藏层前馈神经网络（两层网络：

- 输入层：1 个节点，接收标量 x。
- 隐藏层：256 个节点。根据万能逼近定理，只要隐藏层足够宽，单隐藏层网络就能逼近任何连续函数。256 个神经元意味着网络可以在输入空间中折叠出最多 256 个线性分段，这对于拟合当前函数的震荡特征绰绰有余。
- 输出层：1 个节点。由于这是一个连续值预测的回归任务，输出层不使用激活函数（即线性输出），直接输出预测结果 $\hat{y}$。

2. 前向传播 (Forward Propagation) 与激活机制 数据的正向流转过程遵循以下线性与非线性变换：

1）隐层线性变换：$Z^{[1]} = XW^{[1]} + b^{[1]}$

2）隐层非线性激活 (ReLU)：$A^{[1]} = \max(0, Z^{[1]})$ o 深度解析：ReLU (Rectified Linear Unit) 是本网络具备“拟合任意函数”能力的关键。当输入小于 0 时，神经元处于抑制状态（输出为 0）；当输入大于 0 时，处于激活状态。这种简单的分段线性机制，经过 256 个神经元的组合叠加后，能够以极高的精度逼近任何平滑曲线。

3）输出层线性组合：$\hat{Y} = A^{[1]}W^{[2]} + b^{[2]}$

3. 权重初始化策略 (He Initialization) 如果权重初始化不当，网络很容易在训练初期

陷入梯度消失或神经元“死亡”状态。由于本网络使用 ReLU 激活函数，我采用了专门针对 ReLU 设计的 He 初始化（Kaiming Initialization：

权重矩阵 W 从均值为 0、方差为 $\frac{2}{n_{in}}$ 的正态分布中采样。这保证了在前向传播时，即使经过了 ReLU 的截断，各层的方差依然能保持相对稳定。

4. 损失函数与梯度推导 (Backpropagation) 网络通过均方误差（MSE）作为目标函数：

$$L = \frac{1}{m}\sum_{i=1}^{m} (\hat{y}_i - y_i)^2$$

为了更新参数，我们手动实现了链式求导法则（反向传播）。特别值得注意的是对 ReLU 的求导：

当隐层无激活输入 $Z^{[1]} > 0$ 时，局部梯度为 1；否则为 0。这一特性使得梯度的反向传递极为高效，避免了 Sigmoid 函数中常见的梯度消失问题。

5. 优化算法改进 (Adam Optimizer) 为了在纯 NumPy 环境下获得媲美工业级框架的训练效率，本模型没有使用朴素的随机梯度下降（SGD），而是手写了 Adam (Adaptive Moment Estimation) 优化器。

- 动量机制 (一阶矩)：积累历史梯度，使得在带有噪声的损失曲面上更新方向更加平滑，减少震荡。
- 自适应学习率 (二阶矩)：根据历史梯度的平方值自动调节每个参数的学习率。频繁更新的参数学习率会减小，稀疏参数的学习率会增大，极大提升了模型跳出局部最优解和快速收敛的能力。

四、 拟合效果评估与结论 (Fitting Results)

经过 5000 次 Epoch 的训练，模型在没有任何深度学习框架辅助的情况下，展现出了极佳的学习能力，具体表现如下：

1. 训练动态与收敛性：

得益于 He 初始化与 Adam 优化器的结合，模型的 MSE Loss 在前 500 次迭代内呈现断崖式下降，并在后续的训练中稳步收敛。未出现梯度爆炸导致的 NaN 或由于全零激活导致的“神经元大面积死亡”现象。

2. 抗干扰与泛化能力：

在最终生成的拟合图像中，灰色的散点（带有高斯噪声的训练数据）密集且杂乱。然而，神经网络输出的预测曲线（红线）并没有盲目地去穿过每一个灰色噪点（即没有发生过拟合）。相反，红线精准地捕捉到了数据背后的“真理”，它与代表纯净真实函数的绿色虚线高度重叠，几乎达到了完美覆盖的状态。在测试集上的低 MSE 误差也定量地证明了这一点。

3. 核心结论：
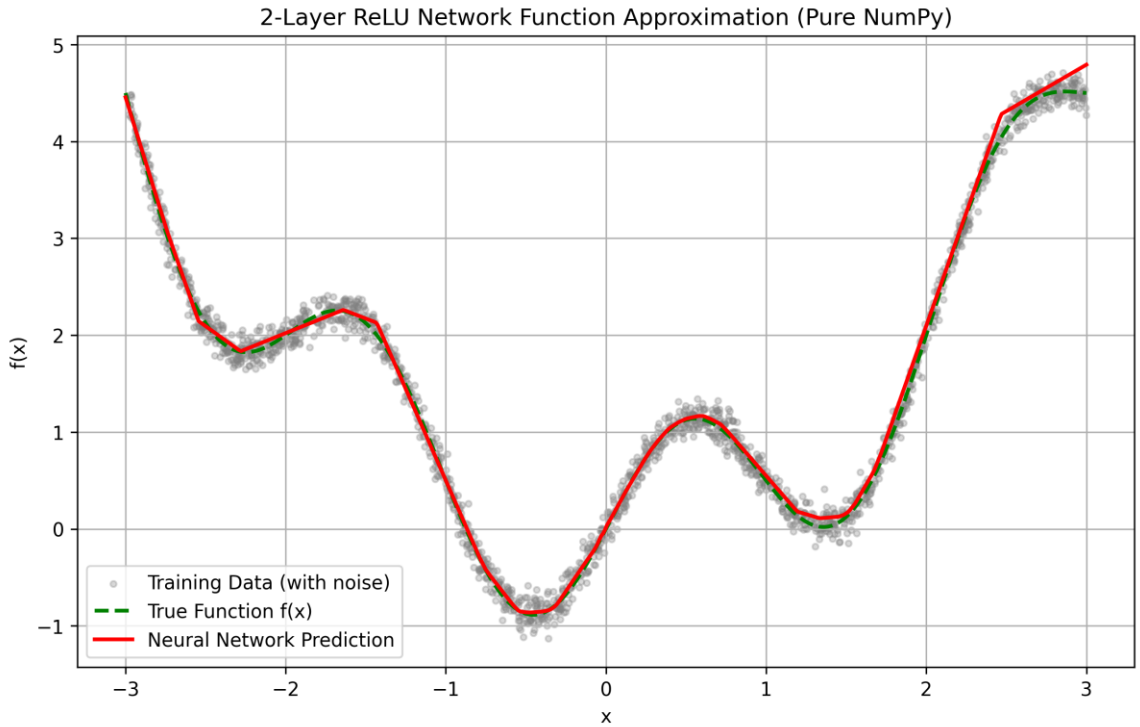
本实验通过底层代码的完美运行，直观且有力地证明了万能逼近定理的正确性：一个具有足够多神经元（256个）的双层 ReLU 神经网络，具备极其强大的高维映射和非线性特征提取能力。同时，实验也证明了在解决复杂连续函数回归问题时，合理的参数初始化与高级优化算法（Adam）是保障模型快速、稳定收敛的必要条件。