深度学习实验报告：基于循环神经网络的唐诗生成

一、RNN、LSTM 与 GRU 模型解析

在进行序列数据（如自然语言处理、诗歌生成）任务时，传统的前馈神经网络无法处理上下文的依赖关系，因此引入了循环神经网络及其变体：

1. RNN (Recurrent Neural Network) 循环神经网络

- **原理**：RNN 的核心思想是“记忆”。它在处理当前时刻的输入时，不仅依赖当前的数据，还会接收来自上一时刻的隐藏状态（Hidden State）。这种将网络输出再次作为输入的循环结构，使其能够处理变长的序列数据。
- **局限性**：标准 RNN 在处理长序列时，由于反向传播中的链式法则，极易出现**梯度消失（Vanishing Gradient）或梯度爆炸（Exploding Gradient）**，导致模型只能记住短期信息，难以捕捉长距离的上下文依赖。

2. LSTM (Long Short-Term Memory) 长短期记忆网络

- **原理**：LSTM 是为了解决 RNN 的长期依赖问题而设计的。本次实验的主干网络即采用了 LSTM。它在 RNN 的基础上引入了“细胞状态（Cell State）”和三个“门（Gate）”机制：
  - **遗忘门（Forget Gate）**：决定丢弃上一时刻的哪些无效信息。
  - **输入门（Input Gate）**：决定将当前时刻的哪些新信息存入细胞状态。
  - **输出门（Output Gate）**：根据当前的细胞状态和输入，决定向下一时刻传递什么隐藏状态。
- **优势**：通过这三个门控机制，LSTM 能够有效地控制信息的积累与遗忘，完美缓解了长序列训练中的梯度消失问题。

3. GRU (Gated Recurrent Unit) 门控循环单元

- **原理**：GRU 可以看作是 LSTM 的轻量级简化版。它将 LSTM 的遗忘门和输入门合并为一个“更新门（Update Gate）”，**并保留了**“重置门（Reset Gate）”。
- **优势**：由于去掉了细胞状态且减少了门控数量，GRU 的参数量更少，训练速度更快，而在很多任务上能达到与 LSTM 相当的性能。

二、 实验流程：诗歌生成的过程叙述

本次实验利用 PyTorch 框架构建了一个基于 LSTM 的字符级语言模型（Character-level Language Model），具体生成过程分为以下几个阶段：

1. **数据预处理与词表构建**

首先读取唐诗文本，剔除过长、过短或包含特殊字符的无效诗句。在每首诗的头部和尾部分别拼接起始符 G (Start) 和终止符 E (End)。随后，统计所有汉字的词频，构建字库（Vocabulary），并生成字符到整数的映射字典 word_to_int。原始汉字序列被转化为模型可处理的数字张量（Tensor）。

2. **模型前向传播与训练**

- **词嵌入（Embedding）**：输入的汉字索引首先通过 nn.Embedding 层，映射为 100 维的稠密词向量，捕捉字符间的语义关系。
- **特征提取（LSTM）**：词向量进入 2 层隐藏维度为 128 的 LSTM 网络，提取时序上下文特征。
- **概率输出（Linear + LogSoftmax）**：LSTM 的输出通过全连接层映射到整个词表大小，再经过 LogSoftmax 转化为预测下一个字的对数概率分布。
- **反向传播**：计算预测值与真实下一个字之间的负对数似然损失（NLLLoss），使用 RMSprop 优化器更新权重，并使用 clip_grad_norm_ 防止梯度爆炸。模型每训练 20 个 Batch 自动保存一次权重。

3. **自回归式诗歌生成（Text Generation）**

在推理阶段（gen_poem 函数），生成过程采用自回归（Autoregressive）方式：

1）输入人为指定的起始字（如“日”）。

2）模型根据该字，输出词表中所有候选字的概率分布。

3）通过贪心搜索（np.argmax），选取概率最大的字作为下一个生成的字。

4）将新生成的字拼接到现有序列中，再次作为输入喂给模型。

5）不断循环上述过程，直到模型预测出终止符 E，或达到设定的最大长度限制（30 字），最后通过 pretty_print_poem 函数格式化输出（根据句号分行）。

三、 实验结果展示

3.1 模型训练过程截图

（PyTorch 版本训练过程记录）**分析：** 从下图中可以看出，在训练初期（Epoch 0），模型的 Loss 值在 6.8 左右徘徊，生成的预测序列多为无意义的填充符（0）。随着 batch 的增加，Loss 呈现明显的下降趋势，说明模型正在有效拟合唐诗数据集，梯度下降方向正确。

```
******************************
epoch   0 batch number 23 loss is:  6.805864334106445
prediction [10, 0, 0, 0, 0, 1, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3]
b_y        [1188, 1188, 1240, 445, 216, 0, 289, 792, 188, 305, 224, 1, 1778, 1003, 300, 4, 683, 0, 445, 115,
13, 74, 55, 1, 3, 3]
******************************
epoch   0 batch number 24 loss is:  6.823913097381592
prediction [10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3]
b_y        [729, 192, 80, 33, 2466, 0, 336, 32, 275, 140, 856, 1, 66, 135, 646, 3090, 528, 0, 182, 117, 1402,
2325, 5367, 1, 3, 3]
******************************
epoch   0 batch number 25 loss is:  6.767613410949707
```

```
24, 1, 518, 30, 70, 163, 67, 581, 451, 0, 190, 203, 23, 14, 394, 555, 134, 1, 3, 3]
******************************
epoch   29 batch number 304 loss is:  4.657336711883545
prediction [10, 6, 4, 19, 4, 152, 84, 0, 10, 64, 9, 5, 4, 149, 24, 1, 10, 165, 4, 21, 25, 10, 53, 0, 10, 6,
4, 73, 10, 11, 7, 1, 11, 152, 17, 137, 9, 7, 85, 0, 17, 44, 12, 59, 10, 16, 12, 1, 4, 545, 84, 5, 9, 42, 792
0, 4, 111, 13, 42, 49, 26, 132, 1, 3, 3]
b_y        [66, 135, 230, 29, 140, 66, 629, 0, 39, 29, 135, 5, 4, 521, 24, 1, 36, 8, 686, 657, 808, 34, 663,
0, 395, 1039, 193, 442, 447, 13, 134, 1, 198, 414, 2181, 148, 181, 409, 4151, 0, 354, 1070, 1741, 1634, 91,
72, 94, 1, 107, 77, 360, 71, 15, 289, 792, 0, 195, 93, 1071, 45, 191, 220, 1559, 1, 3, 3]
******************************
epoch   29 batch number 305 loss is:  4.919675827026367
prediction [10, 5, 4, 8, 0, 0, 20, 0, 10, 108, 9, 129, 4, 82, 115, 1, 10, 64, 4, 1298, 9, 108, 159, 0, 4,
```

3.2 诗歌生成结果展示

为了测试模型的生成能力，修改测试代码，分别以“日、红、山、夜、湖、海、月”作为 begin_word 进行测试。

```
c:\Users\huodi\Desktop\exercise>python -u "c:\Users\huodi\Desktop\exercise\chap6_RNN\tangshi_f
or_pytorch\main.py"
inital  linear weight
乡关路断无人期，不知何处是人间。
inital  linear weight
今日相逢不可见，不知何处是人间。
inital  linear weight
山气深华玉，秋风吹落红妆里。
不知何处无人知，不见青山一枝落。
inital  linear weight
夜雨声，秋风吹落玉重青。
闲来不是无人去，不是无人不可知。
inital  linear weight
湖上春风吹玉船，不知何处是长安。
inital  linear weight
海猿群更空，清夜声声入翠微。
inital  linear weight
不是不知何处去，不知何处是长安。
```

（以下为代码运行的控制台文本输出结果记录：）

- **以“日”字开头：** 乡关路断无人期，不知何处是人间。
- **以“红”字开头：** 今日相逢不可见，不知何处是人间。
- **以“山”字开头：** 山气深华玉，秋风吹落红妆里。 不知何处无人知，不见青山一枝落。
- **以“夜”字开头：** 夜雨声，秋风吹落玉重青。

  闲来不是无人去，不是无人不可知。
- **以“湖”字开头：** 湖上春风吹玉船，不知何处是长安。

- **以“海”字开头：** 海猿群更空，清夜声声入翠微。
- **以“月”字开头：**不是不知何处去，不知何处是长安。